Universidade Presbiteriana Mackenzie
Projeto Aplicado II

Giovanna da Silva Santos 10747002
Julia Petra Teixeira Chaves 10746236
Larissa Jacinto Bispo Christofoletti 10747730

A “Epidemia” de Partos Cesáreos no Brasil

São Paulo
2026

SUMÁRIO

1. **Introdução……..3**
2. **A Organização……...4**
3. **A Problemática: O Desequilíbrio das Vias de Parto……5**
4. **Objetivos e Metas……6**
5. **Apresentação dos Dados (Metadados).....7**
6. **GitHub……..8**
7. **Cronograma……9**
8. **Linguagem de Programação…….……..10**
9. **Análise Exploratória (EDA).....11**
10. **Tratamento dos Dados……..14**
11. **Definição e Descrição das Bases Teóricas dos Métodos……19**
12. **Definição e Descrição de Cálculo de Acurácia……20**
13. **Referências……21**

1. Introdução

O Brasil apresenta uma das maiores taxas de partos cesáreos do mundo, superando os 55% do total de nascimentos, enquanto a Organização Mundial da Saúde (OMS) recomenda um limite de 15%. Esse cenário indica que a decisão pela via de parto não é somente clínica, mas é influenciada por fatores socioeconômicos e operacionais do sistema de saúde. O desafio consiste em identificar quais variáveis (como escolaridade, idade da mãe e dia da semana) são os principais indutores dessa “cultura da cesárea".

2. A Organização

O Sistema Único de Saúde (SUS) é um dos maiores e mais complexos sistemas de saúde pública do mundo, estabelecido pela Constituição Federal de 1988 sob os princípios da universalidade (todos têm direito ao atendimento), integralidade (o cuidado deve considerar a saúde de forma completa) e equidade (priorizar quem mais precisa), estabelecendo que a saúde é um direito de todos e dever do Estado. Ele não se limita ao atendimento hospitalar, abrangendo desde a vigilância sanitária até a gestão de dados epidemiológicos nacionais.

O SUS é considerado um dos maiores sistemas de saúde públicos do mundo, atendendo mais de 200 milhões de pessoas e sendo responsável por grandes campanhas de vacinação e programas de saúde pública.

Os dados que utilizaremos para esse projeto estão concentrados no Departamento de Análise Epidemiológica e Vigilância de Doenças Não Transmissíveis (DAENT) que é subordinado à Secretaria de Vigilância em Saúde e Ambiente (SVSA). O DAENT é como se fosse o “cérebro estatístico” do Ministério da Saúde. Sua função é coletar, processar e analisar dados de sistemas nacionais para identificar riscos à saúde da população. A organização gere o Sistema de Informação sobre Nascidos Vivos (SINASC) Criado em 1990, este sistema padroniza a coleta de informações sobre nascimentos em todo o território nacional através da Declaração de Nascido Vivo (DNV).

3. A Problemática: O Desequilíbrio das Vias de Parto

O problema central consiste na distorção epidemiológica das vias de nascimento no Brasil. A cesariana, que deveria ser uma intervenção de emergência em casos de risco, se tornou a via de parto predominante. O impacto disso é multifatorial:

- Saúde: Aumento de riscos de infecções hospitalares, prematuridade iatrogênica (que são bebês que nascem antes do tempo por erro de cálculo em agendamentos) e recuperação mais lenta.
- Gestão Pública: Custos elevados para o SUS em procedimentos cirúrgicos que poderiam ter sido partos naturais.

Para resolver essa problemática utilizando da Análise de Dados, focaremos no cruzamento de três pilares de dados presentes no SINASC:

- Pilar Socioeconômico: Análise da variável ESCMAE (escolaridade) e RACACOR (cor e raça). A hipótese é que o acesso à informação e o poder aquisitivo influenciam diretamente a taxa de cesáreas.
- Pilar Operacional/Sazonal: Análise das DATAOCOR (data) e LOCNASC (local). Verificação de picos de cirurgias em dias úteis e horários comerciais, sugerindo agendamento por conveniência médica.
- Pilar Clínico/Assistencial: Análise da variável CONSULTAS (número de consultas pré-natal). Verificar se o acompanhamento adequado reduz ou aumenta a chance de uma intervenção cirúrgica.

O grande desafio que esse projeto pretende resolver é a identificação de padrões não lineares. Por exemplo: por que mães com mais de 7 consultas de pré-natal (teoricamente mais informadas) apresentam taxas de cesárea maiores do que aquelas com menos assistência? É uma questão de idade materna ou de oferta ao serviço de saúde?

4. Objetivos e Metas

Temos como objetivo geral desenvolver um modelo analítico e preditivo sobre a incidência de partos cesáreos no Brasil, utilizando a base de dados do SINASC para identificar os principais fatores indutores dessa via de parto.

Processamento de Dados: Realizar a extração, limpeza e tratamento dos microdados do SINASC, transformando arquivos brutos em um dataset estruturado para análise.

Análise Exploratória (EDA): Identificar correlações estatísticas entre variáveis socioeconômicas (escolaridade, raça, idade) e o tipo de parto.

Identificação de Padrões Temporais: Analisar se existe sazonalidade (dias da semana e meses) que sugira o agendamento de cesáreas por conveniência operacional.

Desenvolvimento de Modelo Preditivo: Treinar e validar algoritmos de Machine Learning para classificar a probabilidade e ocorrência de uma cesariana com base no perfil da gestante.

A relevância deste projeto justifica-se em pilares acadêmicos, para aplicação e prática de técnicas de Big Data e Machine learning em uma base real e complexa. Pilares sociais para a contribuição para o debate sobre a saúde da mulher, evidenciando onde o sistema de saúde falha em promover o parto normal. E em pilares organizacionais a fim de, olhar pela perspectiva da organização e fornecer uma ferramenta que vai além da simples visualização, permitindo simular cenários e identificar perfis críticos de pacientes que necessitam de maior apoio no pré-natal pra evitar intervenções desnecessárias.

5. Apresentação dos Dados (Metadados)

Os Dados a serem utilizados, serão extraídos do dicionário oficial do sistema e serão a base da nossa manipulação no Python. Utilizaremos da Variável Alvo que é a variável que tentaremos prever ou explicar:

PARTO | Tipo de parto (1. Vaginal; 2. Cesáreo) | Categórico (Inteiro) | Será nossa variável dependente (Y) no modelo de classificação. |

Além disso, também teremos as nossas variáveis preditoras, que são os dados que o modelo usará para aprender os padrões

1 - Perfil Socioeconômico e Demográfico

ESCMAE: Escolaridade da mãe (anos de estudo)

IDADEMAE - Idade da mãe em anos

RACACOR: Raça/cor da mãe

ESTCIVMAE: Estado Civil da mãe

2 - Histórico pré-natal

CONSULTAS: Número de consultas de pré-natal

QTDFILVIVO: Quantidade de filhos vivos anteriores

GESTACAO: Semanas de gestação

3 - Variáveis Operacionais

DADAOCOR: Data do Nascimento

LOCNASC: Local do nascimento

A utilização desses dados seguirá a pipeline de Ciência de Dados com filtragem e limpeza (para que não haja bias de incerteza), transformação e treinamento do modelo.

6. GitHub

O GitHub é uma plataforma de hospedagem de código e dados baseada em nuvem que utiliza o sistema de controle de versões chamado Git. O Git é como se fosse uma “máquina do tempo” onde registra cada alteração feita nos arquivos, permitindo saber quem alterou algo e quando. O GitHub é a interface social e colaborativa onde esses registros ficam armazenados, permitindo que várias pessoas trabalhem no mesmo código simultaneamente sem apagar o progresso da outra.

Para o nosso projeto, no GitHub servirá para garantir uma colaboração eficiente entre as integrantes do grupo, garantindo versionamento e segurança para que todo o processo seja devidamente protegido.

Link do repositório: https://github.com/Petrachju/Projeto-AplicadoII

7. Cronograma

Etapa 1	
Definição da Organização	
Definição da Problemática	
Exploração do Dataset	
Deadline de Entrega	**16/03/2026**

Etapa 2	
Definição da Linguagem de Programação	
EDA da base	
Tratamento da base	
Definição e descrição das bases teóricas dos métodos	
Definição de cálculo da acurácia	
Deadline de Entrega	**30/03/2026**

Etapa 3	
Entrega do Método Analítico	
Medidas de acurácia	
Descrição dos resultados preliminares	
Esboço do storytelling	
Deadline de Entrega	**27/04/2026**

Etapa 4	
Conclusão do projeto	
Apresentação do storytelling	
Entrega dos scripts	
Entrega da gravação da apresnetação dos resultados	
Deadline de Entrega	**25/05/2026**

8. Linguagem de Programação

Python é uma linguagem de programação de alto nível, criada com o objetivo de ser simples, legível e versátil. Sua sintaxe clara e próxima da linguagem humana facilita o aprendizado e a compreensão do código, tornando o desenvolvimento mais rápido e eficiente. Por esse motivo, Python é amplamente utilizada tanto por iniciantes quanto por profissionais experientes, sendo aplicada em diversas áreas como desenvolvimento web, automação, inteligência artificial e, especialmente, ciência de dados.

No contexto da ciência de dados, Python se destaca por oferecer um ecossistema robusto de bibliotecas especializadas, como Pandas para manipulação de dados, NumPy para cálculos numéricos, Matplotlib e Seaborn para visualização de dados, além de Scikit-learn e TensorFlow para análise estatística e aprendizagem de máquina. Essas ferramentas permitem realizar todo o processo de análise de dados desde a coleta e limpeza até a modelagem e visualização de forma integrada e eficiente.

A escolha do Python para este projeto de ciência de dados se justifica pela sua ampla adoção no mercado e no meio acadêmico, pela grande comunidade de suporte e pela facilidade de integração com diferentes fontes de dados e plataformas. Além disso, Python possibilita a criação de análises reproduzíveis e escaláveis, características essenciais para projetos científicos e profissionais. Dessa forma, utilizar Python contribui tanto para o desenvolvimento técnico do projeto quanto para a formação prática dos alunos, alinhando o aprendizado às demandas atuais da área de dados.

9. Análise Exploratória de Dados (EDA)

Foi realizada uma Análise Exploratória dos dados extraídos para entender o data frame e o padrão que os dados seguem. Para realizar esse projeto, as bases de dados analisadas são dos anos de 2022 e 2023.

Base de 2023

Tamanho: o df de 2022 contém 2.560.319 registros e 13 colunas.

Tipo de dados: A maioria das colunas numéricas (como ***tipo_parto, id_municipio_mae, idade_mae***, etc.) são do tipo *float64*, indicando a presença de valores decimais ou NaN (Não é um Número), que são geralmente usados para representar dados ausentes.

ano é *int64*

sigla_uf **e** ***data_nascimento*** são object, sendo ***data_nascimento*** uma string que precisará ser convertida para um formato de data/hora para análises temporais.

Valores Ausentes

tipo_parto, id_municipio_mae, quantidade_filhos_vivos, quantidade_parto_normal, quantidade_parto_cesareo, idade_mae, escolaridade_mae, raca_cor_mae, semana_gestacao e tipo_parto_1 apresentam um número significativo de valores ausentes. A coluna ***quantidade_parto_normal e quantidade_parto_cesareo*** se destacam com mais de 2 milhões de nulos, e ***escolaridade_mae*** com mais de 1 milhão. Isso exigirá um tratamento cuidadoso (imputação, remoção ou análise separada).

Estatísticas Descritivas

ano: consistentemente 2022.

idade_mae: Varia de 10 a 59 anos, com média de aproximadamente 26 anos.

semana_gestacao: Varia de 1 a 63, com média em torno de 38 semanas, o que é esperado para gestações a termo

	0
ano	0
sigla_uf	0
tipo_parto	1607
id_municipio_mae	76351
quantidade_filhos_vivos	40943
quantidade_parto_normal	63222
quantidade_parto_cesareo	71201
idade_mae	24
escolaridade_mae	13137
raca_cor_mae	68364
semana_gestacao	24610
data_nascimento	0
tipo_parto_1	1607

dtype: int64

Resumo EDA para o df de 2022.

Base de 2023

Tamanho: O df de 2023 é menor contendo 986.591 registros e as mesmas 13 colunas.

Tipo de dados: Os tipos de dados são consistentes com df1 ***(float64, int64, object)***.

Valores Ausentes
Similar ao df de 2022, odf de 2023 também possui valores ausentes em diversas colunas numéricas, incluindo ***tipo_parto, id_municipio_mae, quantidade_filhos_vivos, quantidade_parto_normal, quantidade_parto_cesareo, idade_mae, escolaridade_mae, raca_cor_mae, semana_gestacao e tipo_parto***_1. A quantidade de nulos em quantidade_parto_normal e quantidade_parto_cesareo é alta (cerca de 900 mil), enquanto outras colunas como ***id_municipio_mae e raca_cor_mae*** também apresentam um número considerável.

Estatísticas descritivas
ano: Consistentemente 2023.

idade_mae: Varia de 10 a 59 anos, com média de aproximadamente 27 anos, ligeiramente superior a 2022.

semana_gestacao: Varia de 1 a 63, com média em torno de 38 semanas, similar a 2022.

	0
ano	0
sigla_uf	0
tipo_parto	826
id_municipio_mae	30652
quantidade_filhos_vivos	16154
quantidade_parto_normal	23472
quantidade_parto_cesareo	25702
idade_mae	6
escolaridade_mae	4526
raca_cor_mae	23132
semana_gestacao	9498
data_nascimento	0
tipo_parto_1	826

dtype: int64

Resumo EDA para o df de 2023.

10. Tratamento dos Dados

ARQUIVOS GERADOS - PROJETO SINASC

Visão Geral

O processo de ETL (Extração, Transformação e Carga) dos microdados do SINASC resultou na
geração de três conjuntos de arquivos, organizados por finalidade: visualizações gráficas,
relatórios analíticos e banco de dados SQLite para consultas avançadas.

10.1. GRÁFICOS DE VISUALIZAÇÃO (Pasta: raiz do projeto)

Os gráficos foram gerados a partir do dataset unificado (2022-2023) e fornecem uma análise
visual rápida dos principais indicadores de saúde materno-infantil

Arquivo	Descrição	Principais Insights
unificado_cesarea_por_idade.png	Gráfico de barras mostrando a taxa de cesárea por faixa etária da mãe	Permite identificar grupos etários com maior incidência de partos cesáreos
unificado_distribuicao_uf.png	Distribuição geográfica dos nascimentos por Unidade Federativa	Destaca as regiões com maior volume de nascimentos no período
unificado_escolaridade.png	Distribuição dos nascimentos conforme escolaridade da mãe	Revela o perfil educacional das parturientes
unificado_gestacao.png	Classificação dos nascimentos por idade gestacional (pré-termo, termo, pós-termo)	Evidencia a prevalência de partos prematuros na base
unificado_idade_mae.png	Histograma da idade materna com curva de distribuição	Mostra a concentração etária e a idade média das mães
unificado_raca_cor.png	Distribuição por raça/cor autodeclarada da mãe	Apresenta o perfil étnico-racial da população estudada
unificado_tipo_parto.png	Gráfico de pizza comparando partos vaginais e cesáreos	Demonstra a taxa geral de cesárea no período analisado

Formato: PNG (alta resolução, 300 dpi) - adequado para inclusão em relatórios, apresentações e publicações.

10.2. RELATÓRIOS ANALÍTICOS (Pasta: relatorios/)

Relatórios estruturados em formato CSV e TXT, contendo estatísticas detalhadas extraídas da
base unificada. Estes arquivos podem ser abertos em planilhas eletrônicas (Excel, Google
Sheets) ou processados em ferramentas de BI.

10.3 RELATÓRIOS DE DISTRIBUIÇÃO

Arquivo	Conteúdo	Colunas Principais
unificado_distribuicao_ano.csv	Total de nascimentos por ano	ano, quantidade, percentual
unificado_distribuicao_uf.csv	Nascimentos por Unidade Federativa	uf, quantidade, percentual
unificado_distribuicao_filhos.csv	Distribuição do número de filhos vivos	filhos_vivos, quantidade, percentual
unificado_faixa_etaria.csv	Distribuição por faixa etária da mãe	faixa_etaria, quantidade, percentual

10.4. RELATÓRIOS TEMÁTICOS

Arquivo	Conteúdo	Colunas Principais
unificado_tipo_parto.csv	Distribuição por tipo de parto	tipo_parto, quantidade, percentual
unificado_raca_cor.csv	Distribuição por raça/cor da mãe	raca_cor, quantidade, percentual
unificado_escolaridade.csv	Distribuição por escolaridade	escolaridade, quantidade, percentual
unificado_gestacao.csv	Classificação por idade gestacional	classificacao, quantidade, percentual

10.5. RELATÓRIOS ESTATÍSTICOS E CRUZAMENTOS

Arquivo	Conteúdo	Colunas Principais
unificado_estatisticas_idade.csv	Estatísticas descritivas da idade materna	estatistica (média, mediana, mínimo, máximo, desvio), valor
unificado_estatisticas_filhos.csv	Estatísticas de filhos vivos	estatistica (média, mediana, máximo), valor
unificado_cruzamento_idade_parto.csv	Relação entre faixa etária e tipo de parto	faixa_etaria, Vaginal, Cesáreo, total, percentuais
unificado_cruzamento_escolaridade_parto.csv	Relação entre escolaridade e tipo de parto	escolaridade, Vaginal, Cesáreo, total, percentuais
unificado_resumo_geral.csv	Indicadores consolidados	indicador, valor
unificado_relatorio.txt	Relatório completo em formato texto	-

10.6. ARQUIVOS COMPACTADOS

Arquivo	Conteúdo
unificado_relatorios.zip	Todos os relatórios CSV e TXT compactados para download
unificado_graficos.zip	Todos os gráficos PNG compactados para download

10.7. BANCO DE DADOS SQLITE (Pasta: raiz do projeto)

Arquivos gerados para consultas avançadas utilizando linguagem SQL, permitindo análises mais complexas e personalizadas.

Arquivo	Tamanho	Descrição
sinasc_simples.db	~200-300 MB	Banco de dados SQLite contendo todos os registros tratados (2022-2023) com estrutura otimizada e índices para consultas rápidas

10.8. SCRIPTS DE CONSULTA SQL

Arquivo	Descrição
consultas_sinasc.sql	Arquivo com consultas SQL predefinidas para análises comuns (total por ano, taxa de cesárea por UF, idade média, etc.)
consultas_simples.sql	Versão simplificada com consultas básicas para usuários iniciantes

10.9. Índices Criados

Para otimização de consultas, foram criados índices nas colunas:
ano (para consultas temporais)
uf (para análises geográficas)
tipo_parto (para análises de via de parto)
idade_mae (para análises etárias)
raca_cor (para análises étnico-raciais)

10.10. ESTRUTURA DO BANCO DE DADOS

Campo	Tipo	Descrição
id	INTEGER	Chave primária auto-incrementada
ano	INTEGER	Ano do nascimento (2022 ou 2023)
uf	TEXT	Unidade Federativa (sigla)
tipo_parto	TEXT	Vaginal ou Cesáreo
idade_mae	INTEGER	Idade da mãe em anos (valores válidos: 10-50)
filhos_vivos	INTEGER	Número de filhos vivos
escolaridade	TEXT	Nível de escolaridade categorizado
raca_cor	TEXT	Raça/cor autodeclarada
gestacao	TEXT	Classificação da idade gestacional

10.11. RESUMO ESTATÍSTICO DOS ARQUIVOS GERADOS

Categoria	Quantidade	Formato	Tamanho Aproximado
Gráficos	7 arquivos	PNG	~400 KB
Relatórios CSV	13 arquivos	CSV	~2 MB
Relatório TXT	1 arquivo	TXT	~50 KB
Arquivos Compactados	2 arquivos	ZIP	~500 KB
Banco SQLite	1 arquivo	DB	~200-300 MB
Scripts SQL	2 arquivos	SQL	~10 KB

11. Definição e Descrição das Bases Teóricas dos Métodos

O projeto utiliza uma abordagem de ciência de dados fundamentada em três pilares metodológicos para investigar a prevalência de cesáreas no Brasil:

- **Análise Exploratória de Dados (EDA) e Estatística Descritiva:** Baseia-se na extração de tendências centrais e dispersão de variáveis do SINASC, como IDADEMAE (média de 26-27 anos) e SEMANAGESTAC. A fundamentação teórica foca na identificação de padrões não lineares e correlações entre fatores socioeconômicos (escolaridade e raça) e a via de parto.

- **Processamento e Limpeza de Dados:** Utiliza bibliotecas do ecossistema Python (Pandas e NumPy) para o tratamento de valores ausentes e inconsistências. A base teórica foca na integridade dos dados, fundamental para mitigar o viés de incerteza: a curadoria rigorosa de metadados e a validação de grandes volumes de microdados governamentais.

- **Machine Learning (Aprendizado de Máquina):** Fundamenta-se no treinamento de algoritmos de classificação para prever a variável alvo PARTO (Vaginal ou Cesáreo). O método utiliza variáveis preditoras clínicas, operacionais e demográficas para classificar a probabilidade de intervenção cirúrgica com base no perfil da gestante.

12. Definição e Descrição de Cálculo de Acurácia

A acurácia do projeto será avaliada de forma multidimensional, garantindo a precisão tanto do modelo preditivo quanto da análise estatística:

- **Medidas de Performance do Modelo:** A acurácia será calculada através da comparação entre as previsões do algoritmo de Machine Learning e os dados reais de teste (Y), utilizando métricas de classificação para determinar a taxa de acerto na identificação de partos cesáreos.

- **Acurácia de Integridade (Data Quality):** Avalia-se a precisão da base através da análise de completude (taxa de valores nulos). A consistência é verificada por meio do cruzamento de variáveis redundantes no Python, garantindo que o dataset estruturado reflita fielmente a realidade epidemiológica do SUS.

- **Validação de Hipóteses (Acurácia Analítica):** O sucesso da análise é medido pela capacidade do modelo em validar as hipóteses do projeto, como a correlação entre o número de consultas pré-natal e a conveniência médica no agendamento de cirurgias (Análise Sazonal/Operacional).

13. Referências

MINISTERIO DA SAÚDE. Sistema único de Saúde (SUS). Governo do Brasil, 2026. Disponível em https://www.gov.br/saude/pt-br/sus. Acesso em 10 mar 2026.

MINISTÉRIO DA SAÚDE. Departamento de Análise Epidemiológica e Vigilância de Doenças Não Transmissíveis. Governo do Brasil, 2026. Disponível em https://svs.aids.gov.br/daent/centrais-de-conteudos/paineis-de-monitoramento/natalidade/regularidade. Acesso em 12 mar 2026.

MINISTÉRIO DA SAÚDE. SUS. Sistema de Informações sobre Nascidos Vivos. Governo do Brasil, 2026. Disponível em https://www.gov.br/saude/pt-br/composicao/svsa/sistemas-de-informacao/sinasc. Acesso em 12 mar 2026.

MINISTÉRIO DA SAÚDE. DataSUS. Governo do Brasil, 2026. Disponível em: http://siab.datasus.gov.br/DATASUS/index.php?area=060305. Acesso em 10 mar 2026.