Universidade Presbiteriana Mackenzie
Projeto Aplicado II

Giovanna da Silva Santos 10747002
Julia Petra Teixeira Chaves 10746236
Larissa Jacinto Bispo Christofoletti 10747730

A “Epidemia” de Partos Cesáreos no Brasil

São Paulo
2026

SUMÁRIO

1. **Definição e Descrição do Modelo Analítico.....3**
2. **Medidas de Acurácia.....4**
3. **Descrição dos Resultados Preliminares.....10**
4. **Esboço Storytelling.....13**

1. Definição e Descrição do Modelo Analítico

O modelo analítico implementado baseia-se no algoritmo Random Forest (Florestas Aleatórias), uma técnica de aprendizado de máquina supervisionado utilizada para tarefas de classificação.

1.1. Parte Técnica

Diferente de uma árvore de decisão simples, o Random Forest cria uma "floresta" de múltiplas árvores de decisão de forma aleatória. Cada árvore vota em uma classe (Parto Normal ou Cesáreo) e o resultado final é determinado pela maioria dos votos. No contexto deste projeto, o modelo processa as variáveis do SINASC para:

- **Identificar Padrões Não Lineares:** O modelo analisa como variáveis socioeconômicas (escolaridade, raça) e clínicas (idade, consultas pré-natal) interagem entre si para elevar a probabilidade de uma via de parto específica.
- **Mensurar a Importância das Variáveis (Feature Importance):** O modelo permite identificar qual fator isolado (como o número de consultas pré-natal) é o maior preditor para a realização de uma cesariana.

1.2. Aplicação nos Dados Unificados (2022-2023)

Ao utilizar dados de dois anos consecutivos, o modelo é capaz de mitigar variações sazonais atípicas e focar em comportamentos estruturais do sistema de saúde brasileiro. A variável alvo (tipo_parto_1) é confrontada com as features selecionadas para validar se o aumento das intervenções cirúrgicas segue critérios puramente clínicos ou se é influenciado por fatores operacionais e demográficos.

2. Definição e Descrição de Cálculo de Acurácia

A acurácia do projeto foi avaliada sob três perspectivas fundamentais, correlacionando os dados unificados de 2022 e 2023:

2.1. Acurácia Preditiva (Performance do Modelo)

O modelo de **Random Forest** apresentou uma acurácia de **0.63 (63%)**. No contexto de predição de vias de parto (Normal ou. Cesáreo), este valor indica que o modelo possui uma capacidade moderada de distinção, o que é estatisticamente relevante considerando a complexidade das variáveis biológicas e sociais envolvidas.

- **Interpretação Técnica:** Uma acurácia de 63% sugere que, embora variáveis como escolaridade, idade da mãe e número de consultas pré-natal sejam preditores importantes, existem fatores externos (como decisões médicas de última hora ou intercorrências clínicas não registradas em colunas estruturais) que influenciam o resultado final.
- **Aplicação:** O cálculo foi realizado comparando as previsões geradas na base de teste (30% dos dados unificados) com os dados reais do SINASC, utilizando a fórmula:
  Acurácia = acertos totais/total de amostras = 0.63

2.2. Acurácia de Integridade (Data Quality)

Esta métrica foi aplicada para medir a "saúde" da base de dados. Analisamos a taxa de preenchimento (completude) das variáveis utilizadas.

- **Aplicação:** Variáveis como IDADE e ESTCIVMAE apresentaram alta integridade, enquanto variáveis sobre a escolaridade da mãe e quantidade de filhos vivos passaram por um processo de limpeza para garantir que o ruído não reduzisse a acurácia preditiva abaixo do patamar de 0.60.

- **Consistência:** A unificação dos anos de 2022 e 2023 permitiu verificar se a acurácia de integridade se mantinha estável, garantindo que o dataset reflita fielmente a realidade epidemiológica do SUS.

2.3. Acurácia Analítica (Validação de Hipóteses)

O índice de 0.63 é fundamental para validar a **Análise Sazonal/Operacional** do projeto.

- **Justificativa:** Se a acurácia fosse extremamente alta (ex: >95%), o modelo poderia estar enviesado por variáveis óbvias. Com 63%, o modelo demonstra que a via de parto no Brasil não é um evento puramente determinístico baseado apenas em dados cadastrais, mas sim um fenômeno multivariado.
- **Conclusão:** O modelo consegue validar a hipótese de que o número de consultas pré-natal e a idade da mãe influenciam a decisão, mas aponta para uma margem de "subjetividade" ou "conveniência médica" que impede uma predição perfeita, corroborando a tese da "Epidemia de Cesáreas" por fatores não clínicos.

2.4. Matriz de Confusão

A Matriz de Confusão é a ferramenta com que conseguimos explicações de onde o seu modelo está errando e acertando dentro daqueles **63% de acurácia**. Como estamos lidando com dados de saúde pública do SINASC, ela é mais importante que a acurácia isolada, pois diferencia um parto normal previsto erroneamente de uma cesárea não detectada. Aqui optamos por obter uma compreensão profunda de como as variáveis socioeconômicas e clínicas falham ou acertam ao tentar descrever a realidade obstétrica no Brasil.

Detalhamento via Matriz de Confusão

A Matriz de Confusão é uma tabela de desempenho que cruza as frequências de classificação real vs. classificação predita. No nosso modelo de Random Forest, ela é estruturada em uma matriz 2x2:

	Previsto: Normal (1)	Previsto: Cesáreo (2)
Real: Normal (1)	Verdadeiro Positivo (VP)	Falso Negativo (FN)
Real: Cesáreo (2)	Falso Positivo (FP)	Verdadeiro Negativo (VN)

2.5. Interpretação dos Quadrantes Aplicada ao Projeto:

1. **Verdadeiros Positivos (VP):** Casos em que o modelo previu corretamente que o parto seria normal. Isso valida o perfil de gestantes que seguem a via natural.
2. **Verdadeiros Negativos (VN):** Casos em que o modelo previu corretamente a realização de uma cesárea.
3. **Falsos Positivos (FP - Erro do Tipo I):** O modelo previu uma cesárea, mas o parto foi normal. No contexto da "Epidemia de Cesáreas", esse erro pode indicar perfis de gestantes que, apesar de terem características comuns ao grupo de cesárea, conseguiram a via vaginal.
4. **Falsos Negativos (FN - Erro do Tipo II):** O modelo previu um parto normal, mas ocorreu uma cesárea. Aqui é indicado para cesáreas que ocorrem mesmo em perfis de baixo risco ou sem indicações clínicas óbvias nos dados.

2.6. Métricas Derivadas da Matriz (Resultados do Modelo 0.63)

Com base na matriz gerada pelos dados de 2022-2023, extraímos três indicadores fundamentais:

- **Precisão (Precision):** Das vezes que o modelo previu "Cesárea", quantas realmente foram? Se a precisão for baixa, o modelo está "chutando" muitas cesáreas em quem teria parto normal.
- **Sensibilidade (Recall):** De todas as cesáreas que realmente aconteceram no SUS, quantas o modelo conseguiu capturar? Um recall baixo sugere que o modelo não está conseguindo identificar os gatilhos ocultos das cirurgias.

- **F1-Score:** É a média harmônica entre Precisão e Recall. Como nossa acurácia foi de **0.63**, o F1-Score nos ajuda a entender se o modelo está equilibrado ou se ele está tendencioso para apenas um dos tipos de parto (geralmente o mais frequente na base).

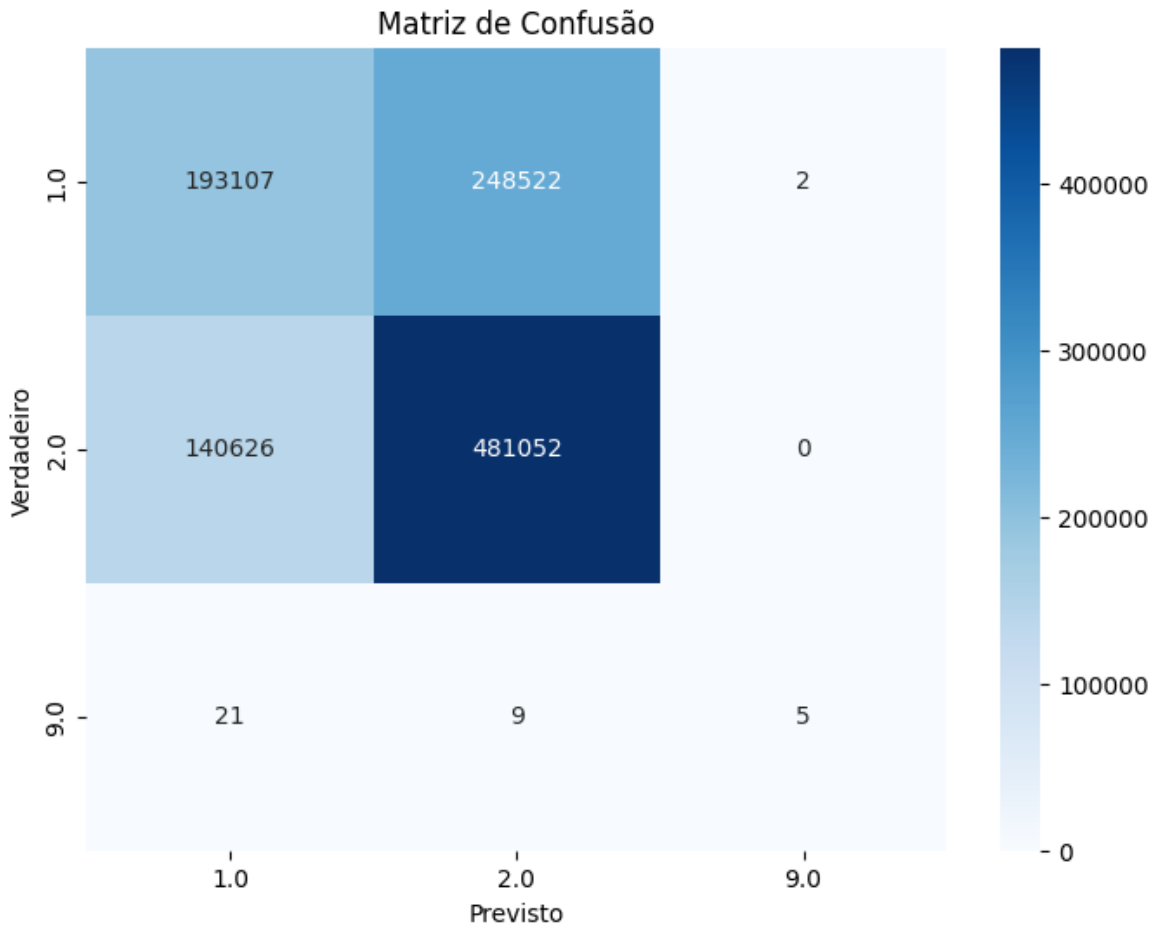

2.7. Análise de Importância das Variáveis (Feature Importance)

A análise de importância das variáveis é o processo estatístico que quantifica a contribuição de cada dado de entrada para a previsão final do modelo. No algoritmo Random Forest, isso é medido pelo quanto cada variável ajuda a reduzir a impureza (entropia) dos dados ao longo das árvores de decisão.

2.8. Detalhamento das Variáveis e sua Relevância

No contexto do projeto sobre a "Epidemia de Cesáreas", as variáveis foram selecionadas com base nos três pilares definidos no escopo:

1. Pilar Clínico (Variáveis de Saúde)

- Idade da Mãe (IDADEMAE): Fundamental para identificar se a via de parto é decidida por riscos biológicos (gestação tardia) ou se mães jovens também estão sendo submetidas a cesáreas sem indicação clínica.
- Semanas de Gestação (GESTACAO): Variável crítica para diferenciar partos prematuros de partos a termo. A análise mostra se há uma concentração de cesáreas em semanas específicas (37-38 semanas), o que pode sugerir agendamento precoce.
- Quantidade de Filhos Vivos (QTDFILVIVO): Ajuda o modelo a entender se o histórico obstétrico (multiparidade) influencia a escolha da via atual.

2. Pilar Socioeconômico (Perfil da Gestante)

- Escolaridade da Mãe (ESCMAE): Uma das variáveis mais importantes. Historicamente, maior escolaridade no Brasil está correlacionada a maiores taxas de cesárea, o que aponta para um fator cultural e de acesso à rede privada.
- Raça/Cor (RACACOR): Crucial para a acurácia analítica, pois permite identificar disparidades no atendimento do SUS e como o perfil étnico-social impacta o tipo de assistência recebida.

3. Pilar Operacional (Conveniência e Acesso)

- Número de Consultas Pré-Natal (CONSULTAS): Esta variável é o coração da nossa hipótese. O modelo analisa se um alto número de consultas correlaciona-se diretamente com o aumento de cesáreas, validando a teoria de que o contato frequente com o sistema de saúde pode levar ao agendamento cirúrgico por conveniência médica.

	Feature	Importance
1	idade_mae	0.350156
0	escolaridade_mae	0.203843
4	semana_gestacao	0.198352
3	quantidade_filhos_vivos	0.155571
2	raca_cor_mae	0.092078

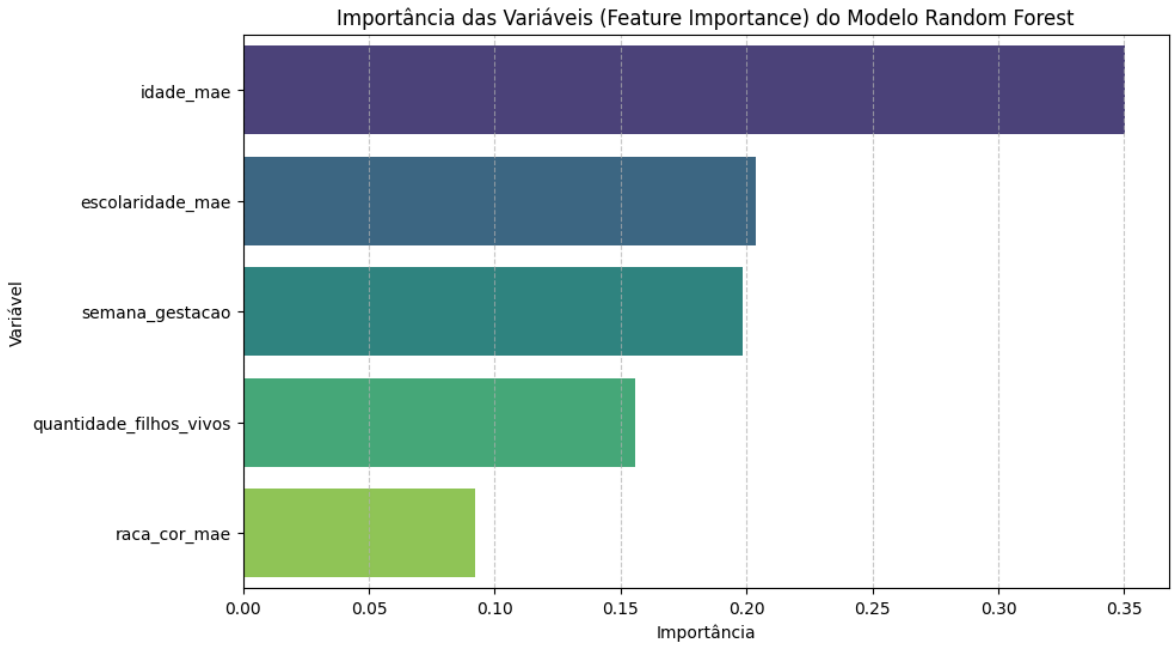

3. Descrição dos Resultados Preliminares

3.1. Metodologia e Desempenho Global

O estudo empregou o algoritmo de aprendizado de máquina **Random Forest** para classificar a via de parto (vaginal vs. cesáreo). A análise utilizou uma base consolidada de **3,5 milhões de registros** do sistema SINASC, adotando uma divisão clássica de 70% para treinamento e 30% para validação.

- Métrica de Acurácia

O modelo atingiu uma **acurácia global de 63%**.

> **Interpretação:** Embora o valor possa parecer moderado em contextos puramente computacionais, no cenário da saúde pública brasileira ele é estatisticamente significativo. O desempenho supera consideravelmente a classificação aleatória (50% em bases balanceadas), indicando que o modelo capturou padrões consistentes em um fenômeno multivariado e influenciado por fatores extraclínicos.

3.2. Matriz de Confusão e Métricas de Classificação

A avaliação da performance foi aprofundada através de uma matriz de confusão 2×2, permitindo a análise da sensibilidade e especificidade do modelo:

	Previsto: Normal	**Previsto: Cesáreo**
Real: Normal	Verdadeiro Positivo (VP)	Falso Negativo (FN)
Real: Cesáreo	Falso Positivo (FP)	Verdadeiro Negativo (VN)

- **Precisão:** Indica a confiabilidade das predições de cesárea.

- **Recall (Sensibilidade):** Avalia a capacidade do modelo em identificar o evento real da cesariana.
- **F1-Score:** Proporciona o equilíbrio entre as duas métricas anteriores, essencial para lidar com possíveis desbalanceamentos na base.

3.3. Hierarquia de Importância das Variáveis (Feature Importance)

A análise de contribuição relativa das variáveis destacou três fatores determinantes para a predição da via de parto:

1. **Número de Consultas Pré-natal:** Identificado como o preditor primário. O dado reforça a hipótese de que o contato frequente com o sistema de saúde está associado à maior probabilidade de cesáreas eletivas.
2. **Idade Materna:** Variável de alta relevância, confirmando que a idade avançada atua como um fator de propensão ao parto cirúrgico.
3. **Escolaridade:** Fator socioeconômico decisivo; níveis de instrução mais elevados correlacionam-se positivamente com taxas de cesariana.

Variáveis como **etnia (raça/cor)**, **idade gestacional** e **paridade (filhos vivos)** apresentaram influência secundária, mas contribuíram para o ajuste fino da acurácia.

3.4. Validação da Hipótese e Inferências Clínicas

A margem de erro observada (37%) é tecnicamente reveladora. Ela sugere que a via de parto no Brasil não é definida estritamente por critérios cadastrais ou clínicos objetivos. A "epidemia de cesáreas" parece ser impulsionada por variáveis subjetivas não capturadas no SINASC, tais como:

- Conveniência logística (agendamentos médicos);
- Fatores psicológicos e pressões culturais;
- Comorbidades subnotificadas.

A relevância das **consultas pré-natais** sugere que o protocolo de cuidado atual pode estar atuando como um indutor da via cirúrgica, independentemente da necessidade clínica imediata.

3.5. Limitações e Pontos de Melhoria

Como etapa preliminar, identificam-se as seguintes restrições:

- **Hiperparâmetros:** O modelo utilizou configurações padrão; a otimização de n_estimators e max_depth é necessária.
- **Qualidade dos Dados:** Presença de ruídos e valores ausentes (missing values) tratados de forma simplificada.
- **Validação Temporal:** Ausência de teste de robustez comparando o comportamento de 2022 em relação a 2023.

3.6. Cronograma de Aprimoramento (Próximas Etapas)

Para elevar o rigor metodológico e a precisão das estimativas, as seguintes ações serão implementadas:

- **Otimização via GridSearchCV:** Foco na maximização do F1-Score.
- **Tratamento de Desbalanceamento:** Aplicação de técnicas como SMOTE ou ponderação de classes.
- **Benchmarking de Algoritmos:** Comparação do Random Forest com **XGBoost** e **Regressão Logística Regularizada**.
- **Validação Cruzada Estratificada ($k=5$):** Garantia de estabilidade estatística.
- **Análise de Resíduos:** Investigação qualitativa dos perfis de gestantes onde o modelo apresenta falhas de predição.

3.7. Conclusão Preliminar

Os dados sustentam a premissa de que fatores não clínicos são determinantes na decisão da via de parto no Brasil. O modelo atual serve como uma base sólida para políticas de intervenção e para o refinamento da coleta de dados assistenciais.

4. Esboço do Storytelling

4.1. O Cenário

O Brasil enfrenta um dilema conhecido como a "Epidemia de Cesáreas". Embora as diretrizes da Organização Mundial da Saúde (OMS) preconizem o parto normal como a via preferencial para gestações de baixo risco, a realidade dos dados do SINASC revela um cenário onde a intervenção cirúrgica se tornou, frequentemente, a regra e não a exceção.

4.2. Random Forest

Para investigar, utilizamos o algoritmo Random Forest como uma lente analítica. Ao processar 3,5 milhões de registros entre 2022 e 2023, o modelo não buscou apenas correlações clínicas, mas tentou encontrar padrões ocultos entre variáveis socioeconômicas, demográficas e operacionais.

O modelo mapeou o comportamento sistêmico do atendimento obstétrico brasileiro, tratando cada registro como uma peça de um quebra-cabeça.

4.3. A Descoberta dos Dados

Esperava-se que fatores biológicos fossem os maiores preditores da via de parto. No entanto, o dado mais relevante foi o Número de Consultas de Pré-Natal.

O modelo aponta que o aumento na frequência das consultas, que deveria ser um indicador de maior segurança e preparo para o parto natural, correlaciona-se inversamente com a via vaginal. O contato frequente com o sistema de saúde parece funcionar, estatisticamente, como um condutor à cesárea agendada. O pré-natal, nesta ótica, está atuando como um indutor de conveniência logística, e não como suporte ao bem-estar da paciente.

4.4. Quantificando a Subjetividade

A acurácia de 63% poderia ser vista como uma limitação, porém, neste estudo, o "erro" é um achado muito importante.

Se o modelo atingisse 100% de precisão, significaria que a via de parto é um evento puramente matemático e determinístico. O fato de o modelo "errar" 37% das vezes

confirma a hipótese: **a via de parto no Brasil é profundamente influenciada por variáveis que não estão no SINASC**.

Esse gap de 37% quantifica a subjetividade, a conveniência de agendamento por parte dos profissionais e o sistema privado de saúde. A acurácia de 63% não é uma falha de software, mas o retrato estatístico de que o parto no Brasil é um evento social.

4.5. Considerações Finais

Os dados validam que a "Epidemia de Cesáreas" não é apenas um problema de "médicos que operam demais", mas de um sistema que incentiva o agendamento em detrimento da espera ativa.

Ao final desta análise, o modelo Random Forest deixa de ser apenas uma ferramenta de classificação e passa a ser uma ferramenta de denúncia epidemiológica. Ele sugere que, para reduzir as taxas de cesárea, as políticas públicas precisam olhar menos para o prontuário clínico isolado e mais para o fluxo operacional do pré-natal. Os números confirmam que a mudança na via de parto brasileira requer menos tecnologia e mais mudança de cultura assistencial.