

Universidade Presbiteriana Mackenzie
Projeto Aplicado II

Giovanna da Silva Santos 10747002
Julia Petra Teixeira Chaves 10746236
Larissa Jacinto Bispo Christofolletti 10747730

A “Epidemia” de Partos Cesáreos no Brasil

São Paulo
2026

SUMÁRIO

1. Introdução.....	3
2. A Organização.....	4
3. A Problemática: O Desequilíbrio das Vias de Parto.....	5
4. Objetivos e Metas.....	6
5. Apresentação dos Dados (Metadados).....	7
6. GitHub.....	8
7. Cronograma.....	9
8. Linguagem de Programação.....	10
9. Análise Exploratória (EDA).....	11
10. Tratamento dos Dados.....	14
11. Definição e Descrição das Bases Teóricas dos Métodos.....	19
12. Definição e Descrição de Cálculo de Acurácia.....	20
13. Definição e Descrição do Modelo Analítico.....	21
14. Definição e Descrição de Cálculo de Acurácia.....	22
15. Descrição dos Resultados Preliminares.....	27
16. Esboço do Storytelling.....	30
17. Apresentação no Youtube.....	32
18. Referências.....	33

1. Introdução

O Brasil apresenta uma das maiores taxas de partos cesáreos do mundo, superando os 55% do total de nascimentos, enquanto a Organização Mundial da Saúde (OMS) recomenda um limite de 15%. Esse cenário indica que a decisão pela via de parto não é somente clínica, mas é influenciada por fatores socioeconômicos e operacionais do sistema de saúde. O desafio consiste em identificar quais variáveis (como escolaridade, idade da mãe e dia da semana) são os principais indutores dessa “cultura da cesárea”.

2. A Organização

O Sistema Único de Saúde (SUS) é um dos maiores e mais complexos sistemas de saúde pública do mundo, estabelecido pela Constituição Federal de 1988 sob os princípios da universalidade (todos têm direito ao atendimento), integralidade (o cuidado deve considerar a saúde de forma completa) e equidade (priorizar quem mais precisa), estabelecendo que a saúde é um direito de todos e dever do Estado. Ele não se limita ao atendimento hospitalar, abrangendo desde a vigilância sanitária até a gestão de dados epidemiológicos nacionais.

O SUS é considerado um dos maiores sistemas de saúde públicos do mundo, atendendo mais de 200 milhões de pessoas e sendo responsável por grandes campanhas de vacinação e programas de saúde pública.

Os dados que utilizaremos para esse projeto estão concentrados no Departamento de Análise Epidemiológica e Vigilância de Doenças Não Transmissíveis (DAENT) que é subordinado à Secretaria de Vigilância em Saúde e Ambiente (SVSA). O DAENT é como se fosse o “cérebro estatístico” do Ministério da Saúde. Sua função é coletar, processar e analisar dados de sistemas nacionais para identificar riscos à saúde da população. A organização gere o Sistema de Informação sobre Nascidos Vivos (SINASC) Criado em 1990, este sistema padroniza a coleta de informações sobre nascimentos em todo o território nacional através da Declaração de Nascido Vivo (DNV).

3. A Problemática: O Desequilíbrio das Vias de Parto

O problema central consiste na distorção epidemiológica das vias de nascimento no Brasil. A cesariana, que deveria ser uma intervenção de emergência em casos de risco, se tornou a via de parto predominante. O impacto disso é multifatorial:

- Saúde: Aumento de riscos de infecções hospitalares, prematuridade iatrogênica (que são bebês que nascem antes do tempo por erro de cálculo em agendamentos) e recuperação mais lenta.
- Gestão Pública: Custos elevados para o SUS em procedimentos cirúrgicos que poderiam ter sido partos naturais.

Para resolver essa problemática utilizando da Análise de Dados, focaremos no cruzamento de três pilares de dados presentes no SINASC:

- Pilar Socioeconômico: Análise da variável ESCMAE (escolaridade) e RACACOR (cor e raça). A hipótese é que o acesso à informação e o poder aquisitivo influenciam diretamente a taxa de cesáreas.
- Pilar Operacional/Sazonal: Análise das DATAOCOR (data) e LOCNASC (local). Verificação de picos de cirurgias em dias úteis e horários comerciais, sugerindo agendamento por conveniência médica.
- Pilar Clínico/Assistencial: Análise da variável CONSULTAS (número de consultas pré-natal). Verificar se o acompanhamento adequado reduz ou aumenta a chance de uma intervenção cirúrgica.

O grande desafio que esse projeto pretende resolver é a identificação de padrões não lineares. Por exemplo: por que mães com mais de 7 consultas de pré-natal (teoricamente mais informadas) apresentam taxas de cesárea maiores do que aquelas com menos assistência? É uma questão de idade materna ou de oferta ao serviço de saúde?

4. Objetivos e Metas

Temos como objetivo geral desenvolver um modelo analítico e preditivo sobre a incidência de partos cesáreos no Brasil, utilizando a base de dados do SINASC para identificar os principais fatores indutores dessa via de parto.

Processamento de Dados: Realizar a extração, limpeza e tratamento dos microdados do SINASC, transformando arquivos brutos em um dataset estruturado para análise.

Análise Exploratória (EDA): Identificar correlações estatísticas entre variáveis socioeconômicas (escolaridade, raça, idade) e o tipo de parto.

Identificação de Padrões Temporais: Analisar se existe sazonalidade (dias da semana e meses) que sugira o agendamento de cesáreas por conveniência operacional.

Desenvolvimento de Modelo Preditivo: Treinar e validar algoritmos de Machine Learning para classificar a probabilidade e ocorrência de uma cesariana com base no perfil da gestante.

A relevância deste projeto justifica-se em pilares acadêmicos, para aplicação e prática de técnicas de Big Data e Machine learning em uma base real e complexa. Pilares sociais para a contribuição para o debate sobre a saúde da mulher, evidenciando onde o sistema de saúde falha em promover o parto normal. E em pilares organizacionais a fim de, olhar pela perspectiva da organização e fornecer uma ferramenta que vai além da simples visualização, permitindo simular cenários e identificar perfis críticos de pacientes que necessitam de maior apoio no pré-natal pra evitar intervenções desnecessárias.

5. Apresentação dos Dados (Metadados)

Os Dados a serem utilizados, serão extraídos do dicionário oficial do sistema e serão a base da nossa manipulação no Python. Utilizaremos da Variável Alvo que é a variável que tentaremos prever ou explicar:

PARTO | Tipo de parto (1. Vaginal; 2. Cesáreo) | Categórico (Inteiro) | Será nossa variável dependente (Y) no modelo de classificação. |

Além disso, também teremos as nossas variáveis preditoras, que são os dados que o modelo usará para aprender os padrões

1 - Perfil Socioeconômico e Demográfico

ESMAE: Escolaridade da mãe (anos de estudo)

IDADEMAE - Idade da mãe em anos

RACACOR: Raça/cor da mãe

ESTCIVMAE: Estado Civil da mãe

2 - Histórico pré-natal

CONSULTAS: Número de consultas de pré-natal

QTDFILVIVO: Quantidade de filhos vivos anteriores

GESTACAO: Semanas de gestação

3 - Variáveis Operacionais

DADAOCOR: Data do Nascimento

LOCNASC: Local do nascimento

A utilização desses dados seguirá a pipeline de Ciência de Dados com filtragem e limpeza (para que não haja bias de incerteza), transformação e treinamento do modelo.

6. GitHub

O GitHub é uma plataforma de hospedagem de código e dados baseada em nuvem que utiliza o sistema de controle de versões chamado Git. O Git é como se fosse uma “máquina do tempo” onde registra cada alteração feita nos arquivos, permitindo saber quem alterou algo e quando. O GitHub é a interface social e colaborativa onde esses registros ficam armazenados, permitindo que várias pessoas trabalhem no mesmo código simultaneamente sem apagar o progresso da outra.

Para o nosso projeto, no GitHub servirá para garantir uma colaboração eficiente entre as integrantes do grupo, garantindo versionamento e segurança para que todo o processo seja devidamente protegido.

Link do repositório: <https://github.com/Petrachju/Projeto-AplicadoII>

7. Cronograma

Etapa 1

Definição da Organização

Definição da Problemática

Exploração do Dataset

Deadline de Entrega

16/03/2026

Etapa 2

Definição da Linguagem de Programação

EDA da base

Tratamento da base

Definição e descrição das bases teóricas dos métodos

Definição de cálculo da acurácia

Deadline de Entrega

30/03/2026

Etapa 3

Entrega do Método Analítico

Medidas de acurácia

Descrição dos resultados preliminares

Esboço do storytelling

Deadline de Entrega

27/04/2026

Etapa 4

Conclusão do projeto

Apresentação do storytelling

Entrega dos scripts

Entrega da gravação da apresentação dos resultados

Deadline de Entrega

25/05/2026

8. Linguagem de Programação

Python é uma linguagem de programação de alto nível, criada com o objetivo de ser simples, legível e versátil. Sua sintaxe clara e próxima da linguagem humana facilita o aprendizado e a compreensão do código, tornando o desenvolvimento mais rápido e eficiente. Por esse motivo, Python é amplamente utilizada tanto por iniciantes quanto por profissionais experientes, sendo aplicada em diversas áreas como desenvolvimento web, automação, inteligência artificial e, especialmente, ciência de dados.

No contexto da ciência de dados, Python se destaca por oferecer um ecossistema robusto de bibliotecas especializadas, como Pandas para manipulação de dados, NumPy para cálculos numéricos, Matplotlib e Seaborn para visualização de dados, além de Scikit-learn e TensorFlow para análise estatística e aprendizagem de máquina. Essas ferramentas permitem realizar todo o processo de análise de dados desde a coleta e limpeza até a modelagem e visualização de forma integrada e eficiente.

A escolha do Python para este projeto de ciência de dados se justifica pela sua ampla adoção no mercado e no meio acadêmico, pela grande comunidade de suporte e pela facilidade de integração com diferentes fontes de dados e plataformas. Além disso, Python possibilita a criação de análises reproduzíveis e escaláveis, características essenciais para projetos científicos e profissionais. Dessa forma, utilizar Python contribui tanto para o desenvolvimento técnico do projeto quanto para a formação prática dos alunos, alinhando o aprendizado às demandas atuais da área de dados.

9. Análise Exploratória de Dados (EDA)

Foi realizada uma Análise Exploratória dos dados extraídos para entender o data frame e o padrão que os dados seguem. Para realizar esse projeto, as bases de dados analisadas são dos anos de 2022 e 2023.

Base de 2023

Tamanho: o df de 2022 contém 2.560.319 registros e 13 colunas.

Tipo de dados: A maioria das colunas numéricas (como **tipo_parto**, **id_municipio_mae**, **idade_mae**, etc.) são do tipo *float64*, indicando a presença de valores decimais ou NaN (Não é um Número), que são geralmente usados para representar dados ausentes.

ano é *int64*

sigla_uf e **data_nascimento** são object, sendo **data_nascimento** uma string que precisará ser convertida para um formato de data/hora para análises temporais.

Valores Ausentes

tipo_parto, **id_municipio_mae**, **quantidade_filhos_vivos**, **quantidade_parto_normal**, **quantidade_parto_cesareo**, **idade_mae**, **escolaridade_mae**, **raca_cor_mae**, **semana_gestacao** e **tipo_parto_1** apresentam um número significativo de valores ausentes. A coluna **quantidade_parto_normal** e **quantidade_parto_cesareo** se destacam com mais de 2 milhões de nulos, e **escolaridade_mae** com mais de 1 milhão. Isso exigirá um tratamento cuidadoso (imputação, remoção ou análise separada).

Estatísticas Descritivas

ano: consistentemente 2022.

idade_mae: Varia de 10 a 59 anos, com média de aproximadamente 26 anos.

semana_gestacao: Varia de 1 a 63, com média em torno de 38 semanas, o que é esperado para gestações a termo

	0
ano	0
sigla_uf	0
tipo_parto	1607
id_municipio_mae	76351
quantidade_filhos_vivos	40943
quantidade_parto_normal	63222
quantidade_parto_cesareo	71201
idade_mae	24
escolaridade_mae	13137
raca_cor_mae	68364
semana_gestacao	24610
data_nascimento	0
tipo_parto_1	1607

dtype: int64

Resumo EDA para o df de 2022.

Base de 2023

Tamanho: O df de 2023 é menor contendo 986.591 registros e as mesmas 13 colunas.

Tipo de dados: Os tipos de dados são consistentes com df1 (*float64, int64, object*).

Valores Ausentes

Similar ao df de 2022, odf de 2023 também possui valores ausentes em diversas colunas numéricas, incluindo **tipo_parto, id_municipio_mae, quantidade_filhos_vivos, quantidade_parto_normal, quantidade_parto_cesareo, idade_mae, escolaridade_mae, raca_cor_mae, semana_gestacao e tipo_parto_1**. A quantidade de nulos em quantidade_parto_normal e quantidade_parto_cesareo é alta (cerca de 900 mil), enquanto outras colunas como **id_municipio_mae e raca_cor_mae** também apresentam um número considerável.

Estatísticas descritivas

ano: Consistentemente 2023.

idade_mae: Varia de 10 a 59 anos, com média de aproximadamente 27 anos, ligeiramente superior a 2022.

semana_gestacao: Varia de 1 a 63, com média em torno de 38 semanas, similar a 2022.

	0
ano	0
sigla_uf	0
tipo parto	826
id_municipio_mae	30652
quantidade_filhos_vivos	16154
quantidade_parto_normal	23472
quantidade_parto_cesareo	25702
idade_mae	6
escolaridade_mae	4526
raca_cor_mae	23132
semana_gestacao	9498
data_nascimento	0
tipo_parto_1	826

dtype: int64

Resumo EDA para o df de 2023.

10. Tratamento dos Dados

ARQUIVOS GERADOS - PROJETO SINASC

Visão Geral

O processo de ETL (Extração, Transformação e Carga) dos microdados do SINASC resultou na geração de três conjuntos de arquivos, organizados por finalidade: visualizações gráficas, relatórios analíticos e banco de dados SQLite para consultas avançadas.

10.1. GRÁFICOS DE VISUALIZAÇÃO (Pasta: raiz do projeto)

Os gráficos foram gerados a partir do dataset unificado (2022-2023) e fornecem uma análise visual rápida dos principais indicadores de saúde materno-infantil

Arquivo	Descrição	Principais Insights
unificado_cesarea_por_idade.png	Gráfico de barras mostrando a taxa de cesárea por faixa etária da mãe	Permite identificar grupos etários com maior incidência de partos cesáreos
unificado_distribuicao_uf.png	Distribuição geográfica dos nascimentos por Unidade Federativa	Destaca as regiões com maior volume de nascimentos no período
unificado_escolaridade.png	Distribuição dos nascimentos conforme escolaridade da mãe	Revela o perfil educacional das parturientes
unificado_gestacao.png	Classificação dos nascimentos por idade gestacional (pré-termo, termo, pós-termo)	Evidencia a prevalência de partos prematuros na base
unificado_idade_mae.png	Histograma da idade materna com curva de distribuição	Mostra a concentração etária e a idade média das mães
unificado_raca_cor.png	Distribuição por raça/cor autodeclarada da mãe	Apresenta o perfil étnico-racial da população estudada
unificado_tipo_parto.png	Gráfico de pizza comparando partos vaginais e cesáreos	Demonstra a taxa geral de cesárea no período analisado

Formato: PNG (alta resolução, 300 dpi) - adequado para inclusão em relatórios, apresentações e publicações.

10.2. RELATÓRIOS ANALÍTICOS (Pasta: relatorios/)

Relatórios estruturados em formato CSV e TXT, contendo estatísticas detalhadas extraídas da base unificada. Estes arquivos podem ser abertos em planilhas eletrônicas (Excel, Google Sheets) ou processados em ferramentas de BI.

10.3 RELATÓRIOS DE DISTRIBUIÇÃO

Arquivo	Conteúdo	Colunas Principais
unificado_distribuicao_ano.csv	Total de nascimentos por ano	ano, quantidade, percentual
unificado_distribuicao_uf.csv	Nascimentos por Unidade Federativa	uf, quantidade, percentual
unificado_distribuicao_filhos.csv	Distribuição do número de filhos vivos	filhos_vivos, quantidade, percentual
unificado_faixa_etaria.csv	Distribuição por faixa etária da mãe	faixa_etaria, quantidade, percentual

10.4. RELATÓRIOS TEMÁTICOS

Arquivo	Conteúdo	Colunas Principais
unificado_tipo_parto.csv	Distribuição por tipo de parto	tipo_parto, quantidade, percentual
unificado_raca_cor.csv	Distribuição por raça/cor da mãe	raca_cor, quantidade, percentual
unificado_escolaridade.csv	Distribuição por escolaridade	escolaridade, quantidade, percentual
unificado_gestacao.csv	Classificação por idade gestacional	classificacao, quantidade, percentual

10.5. RELATÓRIOS ESTATÍSTICOS E CRUZAMENTOS

Arquivo	Conteúdo	Colunas Principais
unificado_estatisticas_idade.csv	Estatísticas descritivas da idade materna	estatistica (média, mediana, mínimo, máximo, desvio), valor
unificado_estatisticas_filhos.csv	Estatísticas de filhos vivos	estatistica (média, mediana, máximo), valor
unificado_cruzamento_idade_parto.csv	Relação entre faixa etária e tipo de parto	faixa_etaria, Vaginal, Cesáreo, total, percentuais
unificado_cruzamento_escolaridade_parto.csv	Relação entre escolaridade e tipo de parto	escolaridade, Vaginal, Cesáreo, total, percentuais
unificado_resumo_geral.csv	Indicadores consolidados	indicador, valor
unificado_relatorio.txt	Relatório completo em formato texto	-

10.6. ARQUIVOS COMPACTADOS

Arquivo	Conteúdo
unificado_relatorios.zip	Todos os relatórios CSV e TXT compactados para download
unificado_graficos.zip	Todos os gráficos PNG compactados para download

10.7. BANCO DE DADOS SQLITE (Pasta: raiz do projeto)

Arquivos gerados para consultas avançadas utilizando linguagem SQL, permitindo análises mais complexas e personalizadas.

Arquivo	Tamanho	Descrição
sinasc_simples.db	~200-300 MB	Banco de dados SQLite contendo todos os registros tratados (2022-2023) com estrutura otimizada e índices para consultas rápidas

10.8. SCRIPTS DE CONSULTA SQL

Arquivo	Descrição
consultas_sinasc.sql	Arquivo com consultas SQL predefinidas para análises comuns (total por ano, taxa de cesárea por UF, idade média, etc.)
consultas_simples.sql	Versão simplificada com consultas básicas para usuários iniciantes

10.9. Índices Criados

Para otimização de consultas, foram criados índices nas colunas:

ano (para consultas temporais)

uf (para análises geográficas)

tipo_parto (para análises de via de parto)

idade_mae (para análises etárias)

raca_cor (para análises étnico-raciais)

10.10. ESTRUTURA DO BANCO DE DADOS

Campo	Tipo	Descrição
id	INTEGER	Chave primária auto-incrementada
ano	INTEGER	Ano do nascimento (2022 ou 2023)
uf	TEXT	Unidade Federativa (sigla)
tipo_parto	TEXT	Vaginal ou Cesáreo
idade_mae	INTEGER	Idade da mãe em anos (valores válidos: 10-50)
filhos_vivos	INTEGER	Número de filhos vivos
escolaridade	TEXT	Nível de escolaridade categorizado
raca_cor	TEXT	Raça/cor autodeclarada
gestacao	TEXT	Classificação da idade gestacional

10.11. RESUMO ESTATÍSTICO DOS ARQUIVOS GERADOS

Categoria	Quantidade	Formato	Tamanho Aproximado
Gráficos	7 arquivos	PNG	~400 KB
Relatórios CSV	13 arquivos	CSV	~2 MB
Relatório TXT	1 arquivo	TXT	~50 KB
Arquivos Compactados	2 arquivos	ZIP	~500 KB
Banco SQLite	1 arquivo	DB	~200-300 MB
Scripts SQL	2 arquivos	SQL	~10 KB

11. Definição e Descrição das Bases Teóricas dos Métodos

O projeto utiliza uma abordagem de ciência de dados fundamentada em três pilares metodológicos para investigar a prevalência de cesáreas no Brasil:

- **Análise Exploratória de Dados (EDA) e Estatística Descritiva:** Baseia-se na extração de tendências centrais e dispersão de variáveis do SINASC, como IDADEMAE (média de 26-27 anos) e SEMANAGESTAC. A fundamentação teórica foca na identificação de padrões não lineares e correlações entre fatores socioeconômicos (escolaridade e raça) e a via de parto.
- **Processamento e Limpeza de Dados:** Utiliza bibliotecas do ecossistema Python (Pandas e NumPy) para o tratamento de valores ausentes e inconsistências. A base teórica foca na integridade dos dados, fundamental para mitigar o viés de incerteza: a curadoria rigorosa de metadados e a validação de grandes volumes de microdados governamentais.
- **Machine Learning (Aprendizado de Máquina):** Fundamenta-se no treinamento de algoritmos de classificação para prever a variável alvo PARTO (Vaginal ou Cesáreo). O método utiliza variáveis preditoras clínicas, operacionais e demográficas para classificar a probabilidade de intervenção cirúrgica com base no perfil da gestante.

12. Definição e Descrição de Cálculo de Acurácia

A acurácia do projeto será avaliada de forma multidimensional, garantindo a precisão tanto do modelo preditivo quanto da análise estatística:

- **Medidas de Performance do Modelo:** A acurácia será calculada através da comparação entre as previsões do algoritmo de Machine Learning e os dados reais de teste (Y), utilizando métricas de classificação para determinar a taxa de acerto na identificação de partos cesáreos.
- **Acurácia de Integridade (Data Quality):** Avalia-se a precisão da base através da análise de completude (taxa de valores nulos). A consistência é verificada por meio do cruzamento de variáveis redundantes no Python, garantindo que o dataset estruturado reflita fielmente a realidade epidemiológica do SUS.
- **Validação de Hipóteses (Acurácia Analítica):** O sucesso da análise é medido pela capacidade do modelo em validar as hipóteses do projeto, como a correlação entre o número de consultas pré-natal e a conveniência médica no agendamento de cirurgias (Análise Sazonal/Operacional).

13. Definição e Descrição do Modelo Analítico

O modelo analítico implementado baseia-se no algoritmo Random Forest (Florestas Aleatórias), uma técnica de aprendizado de máquina supervisionado utilizada para tarefas de classificação.

13.1. Parte Técnica

Diferente de uma árvore de decisão simples, o Random Forest cria uma "floresta" de múltiplas árvores de decisão de forma aleatória. Cada árvore vota em uma classe (Parto Normal ou Cesáreo) e o resultado final é determinado pela maioria dos votos. No contexto deste projeto, o modelo processa as variáveis do SINASC para:

- Identificar Padrões Não Lineares: O modelo analisa como variáveis socioeconômicas (escolaridade, raça) e clínicas (idade, consultas pré-natal) interagem entre si para elevar a probabilidade de uma via de parto específica.
- Mensurar a Importância das Variáveis (Feature Importance): O modelo permite identificar qual fator isolado (como o número de consultas pré-natal) é o maior preditor para a realização de uma cesariana.

13.2. Aplicação nos Dados Unificados (2022-2023)

Ao utilizar dados de dois anos consecutivos, o modelo é capaz de mitigar variações sazonais atípicas e focar em comportamentos estruturais do sistema de saúde brasileiro. A variável alvo (`tipo_parto_1`) é confrontada com as features selecionadas para validar se o aumento das intervenções cirúrgicas segue critérios puramente clínicos ou se é influenciado por fatores operacionais e demográficos.

14. Definição e Descrição de Cálculo de Acurácia

A acurácia do projeto foi avaliada sob três perspectivas fundamentais, correlacionando os dados unificados de 2022 e 2023:

14.1. Acurácia Preditiva (Performance do Modelo)

O modelo de Random Forest apresentou uma acurácia de 0.63 (63%). No contexto de predição de vias de parto (Normal ou. Cesáreo), este valor indica que o modelo possui uma capacidade moderada de distinção, o que é estatisticamente relevante considerando a complexidade das variáveis biológicas e sociais envolvidas.

- **Interpretação Técnica:** Uma acurácia de 63% sugere que, embora variáveis como escolaridade, idade da mãe e número de consultas pré-natal sejam preditores importantes, existem fatores externos (como decisões médicas de última hora ou intercorrências clínicas não registradas em colunas estruturais) que influenciam o resultado final.

- **Aplicação:** O cálculo foi realizado comparando as previsões geradas na base de teste (30% dos dados unificados) com os dados reais do SINASC, utilizando a $\text{Acurácia} = \frac{\text{acertos totais}}{\text{total de amostras}} = 0.63$

14.2. Acurácia de Integridade (Data Quality) fórmula:

Esta métrica foi aplicada para medir a "saúde" da base de dados. Analisamos a taxa de preenchimento (completude) das variáveis utilizadas.

- **Aplicação:** Variáveis como IDADE e ESTCIVMAE apresentaram alta integridade, enquanto variáveis sobre a escolaridade da mãe e quantidade de filhos vivos passaram por um processo de limpeza para garantir que o ruído não reduzisse a acurácia preditiva abaixo do patamar de 0.60. 4

- **Consistência:** A unificação dos anos de 2022 e 2023 permitiu verificar se a acurácia de integridade se mantinha estável, garantindo que o dataset reflita fielmente a realidade epidemiológica do SUS.

14.3. Acurácia Analítica (Validação de Hipóteses)

O índice de 0.63 é fundamental para validar a Análise Sazonal/Operacional do projeto.

- **Justificativa:** Se a acurácia fosse extremamente alta (ex: >95%), o modelo poderia estar enviesado por variáveis óbvias. Com 63%, o modelo demonstra que a via de parto no Brasil não é um evento puramente determinístico baseado apenas em dados cadastrais, mas sim um fenômeno multivariado.

- **Conclusão:** O modelo consegue validar a hipótese de que o número de consultas pré-natal e a idade da mãe influenciam a decisão, mas aponta para uma margem de "subjetividade" ou "conveniência médica" que impede uma predição perfeita, corroborando a tese da "Epidemia de Cesáreas" por fatores não clínicos.

14.4. Matriz de Confusão

A Matriz de Confusão é a ferramenta com que conseguimos explicações de onde o seu modelo está errando e acertando dentro daqueles 63% de acurácia. Como estamos lidando com dados de saúde pública do SINASC, ela é mais importante que a acurácia isolada, pois diferencia um parto normal previsto erroneamente de uma cesárea não detectada. Aqui optamos por obter uma compreensão profunda de como as variáveis socioeconômicas e clínicas falham ou acertam ao tentar descrever a realidade obstétrica no Brasil. Detalhamento via Matriz de Confusão A Matriz de Confusão é uma tabela de desempenho que cruza as frequências de classificação real vs. classificação predita. No nosso modelo de Random Forest, ela é estruturada em uma matriz 2x2:

	Previsto: Normal (1)	Previsto: Cesáreo (2)
Real: Normal (1)	Verdadeiro Positivo (VP)	Falso Negativo (FN)
Real: Cesáreo (2)	Falso Positivo (FP)	Verdadeiro Negativo (VN)

14.5. Interpretação dos Quadrantes Aplicada ao Projeto:

1. Verdadeiros Positivos (VP): Casos em que o modelo previu corretamente que o parto seria normal. Isso valida o perfil de gestantes que seguem a via natural.

2. Verdadeiros Negativos (VN): Casos em que o modelo previu corretamente a realização de uma cesárea.


3. Falsos Positivos (FP - Erro do Tipo I): O modelo previu uma cesárea, mas o parto foi normal. No contexto da "Epidemia de Cesáreas", esse erro pode indicar perfis de gestantes que, apesar de terem características comuns ao grupo de cesárea, conseguiram a via vaginal.

4. Falsos Negativos (FN - Erro do Tipo II): O modelo previu um parto normal, mas ocorreu uma cesárea. Aqui é indicado para cesáreas que ocorrem mesmo em perfis de baixo risco ou sem indicações clínicas óbvias nos dados.

14.6. Métricas Derivadas da Matriz (Resultados do Modelo 0.63)

Com base na matriz gerada pelos dados de 2022-2023, extraímos três indicadores fundamentais:

- **Precisão (Precision):** Das vezes que o modelo previu "Cesárea", quantas realmente foram? Se a precisão for baixa, o modelo está "chutando" muitas cesáreas em quem teria parto normal.
- **Sensibilidade (Recall):** De todas as cesáreas que realmente aconteceram no SUS, quantas o modelo conseguiu capturar? Um recall baixo sugere que o modelo não está conseguindo identificar os gatilhos ocultos das cirurgias.
- **F1-Score:** É a média harmônica entre Precisão e Recall. Como nossa acurácia foi de 0.63, o F1-Score nos ajuda a entender se o modelo está equilibrado ou se ele está tendencioso para apenas um dos tipos de parto (geralmente o mais frequente na base).



14.7. Análise de Importância das Variáveis (Feature Importance)

A análise de importância das variáveis é o processo estatístico que quantifica a contribuição de cada dado de entrada para a previsão final do modelo. No algoritmo Random Forest, isso é medido pelo quanto cada variável ajuda a reduzir a impureza (entropia) dos dados ao longo das árvores de decisão.

14.8. Detalhamento das Variáveis e sua Relevância

No contexto do projeto sobre a "Epidemia de Cesáreas", as variáveis foram selecionadas com base nos três pilares definidos no escopo:

1. Pilar Clínico (Variáveis de Saúde)

- **Idade da Mãe (IDADEMAE):** Fundamental para identificar se a via de parto é decidida por riscos biológicos (gestação tardia) ou se mães jovens também estão sendo submetidas a cesáreas sem indicação clínica.

- **Semanas de Gestação (GESTACAO):** Variável crítica para diferenciar partos prematuros de partos a termo. A análise mostra se há uma concentração de cesáreas em semanas específicas (37-38 semanas), o que pode sugerir agendamento precoce.

- **Quantidade de Filhos Vivos (QTDFILVIVO):** Ajuda o modelo a entender se o histórico obstétrico (multiparidade) influencia a escolha da via atual.

2. Pilar Socioeconômico (Perfil da Gestante)


- **Escolaridade da Mãe (ESCMAE):** Uma das variáveis mais importantes. Historicamente, maior escolaridade no Brasil está correlacionada a maiores taxas de cesárea, o que aponta para um fator cultural e de acesso à rede privada.

- **Raça/Cor (RACACOR):** Crucial para a acurácia analítica, pois permite identificar disparidades no atendimento do SUS e como o perfil étnico-social impacta o tipo de assistência recebida.

3. Pilar Operacional (Conveniência e Acesso)

- **Número de Consultas Pré-Natal (CONSULTAS):** Esta variável é o coração da nossa hipótese. O modelo analisa se um alto número de consultas correlaciona-se diretamente com o aumento de cesáreas, validando a teoria de que o contato frequente com o sistema de saúde pode levar ao agendamento cirúrgico por conveniência médica.

	Feature	Importance
1	idade_mae	0.350156
0	escolaridade_mae	0.203843
4	semana_gestacao	0.198352
3	quantidade_filhos_vivos	0.155571
2	raca_cor_mae	0.092078



15. Descrição dos Resultados Preliminares

15.1. Metodologia e Desempenho Global

O estudo empregou o algoritmo de aprendizado de máquina Random Forest para classificar a via de parto (vaginal vs. cesáreo). A análise utilizou uma base consolidada de 3,5 milhões de registros do sistema SINASC, adotando uma divisão clássica de 70% para treinamento e 30% para validação.

Métrica de Acurácia

O modelo atingiu uma acurácia global de 63%.

Interpretação: Embora o valor possa parecer moderado em contextos puramente computacionais, no cenário da saúde pública brasileira ele é estatisticamente significativo. O desempenho supera consideravelmente a classificação aleatória, indicando que o modelo capturou padrões consistentes em um fenômeno multivariado e influenciado por fatores extra clínicos.

15.2. Matriz de Confusão e Métricas de Classificação A avaliação da performance foi aprofundada através de uma matriz de confusão permitindo a análise da sensibilidade e especificidade do modelo:

	Previsto: Normal	Previsto: Cesáreo
Real: Normal	Verdadeiro Positivo (VP)	Falso Negativo (FN)
Real: Cesáreo	Falso Positivo (FP)	Verdadeiro Negativo (VN)

- **Precisão:** Indica a confiabilidade das predições de cesárea.
- **Recall (Sensibilidade):** Avalia a capacidade do modelo em identificar o evento real da cesariana.
- **F1-Score:** Proporciona o equilíbrio entre as duas métricas anteriores, essencial para lidar com possíveis desbalanceamentos na base.

15.3. Hierarquia de Importância das Variáveis (Feature Importance)

A análise de contribuição relativa das variáveis destacou três fatores determinantes para a predição da via de parto:

1. Número de Consultas Pré-natal: Identificado como o preditor primário. O dado reforça a hipótese de que o contato frequente com o sistema de saúde está associado à maior probabilidade de cesáreas eletivas.

2. Idade Materna: Variável de alta relevância, confirmando que a idade avançada atua como um fator de propensão ao parto cirúrgico.

3. Escolaridade: Fator socioeconômico decisivo; níveis de instrução mais elevados correlacionam-se positivamente com taxas de cesariana. Variáveis como etnia (raça/cor), idade gestacional e paridade (filhos vivos) apresentaram influência secundária, mas contribuíram para o ajuste fino da acurácia.

15.4. Validação da Hipótese e Inferências Clínicas

A margem de erro observada é tecnicamente reveladora. Ela sugere que a via de parto no Brasil não seja definida estritamente por critérios cadastrais ou clínicos objetivos. A "epidemia de cesáreas" parece ser impulsionada por variáveis subjetivas não capturadas no SINASC, tais como:

- Conveniência logística (agendamentos médicos);
- Fatores psicológicos e pressões culturais;
- Comorbidades subnotificadas. A relevância das consultas pré-natais sugere que o protocolo de cuidado atual pode estar atuando como um indutor da via cirúrgica, independentemente da necessidade clínica imediata.

15.5. Limitações e Pontos de Melhoria

Como etapa preliminar, identificam-se as seguintes restrições:

- **Hiperparâmetros:** O modelo utilizou configurações padrão; a otimização de `n_estimators` e `max_depth` é necessária.
- **Qualidade dos Dados:** Presença de ruídos e valores ausentes (missing values) tratados de forma simplificada.
- **Validação Temporal:** Ausência de teste de robustez comparando o comportamento de 2022 em relação a 2023.

15.6. Cronograma de Aprimoramento (Próximas Etapas)

Para elevar o rigor metodológico e a precisão das estimativas, as seguintes ações serão implementadas:

- **Otimização via GridSearchCV:** Foco na maximização do F1-Score.

- **Tratamento de Desbalanceamento:** Aplicação de técnicas como SMOTE ou ponderação de classes.
- **Benchmarking de Algoritmos:** Comparação do Random Forest com XGBoost e Regressão Logística Regularizada.
- **Validação Cruzada Estratificada:** Garantia de estabilidade estatística.
- **Análise de Resíduos:** Investigação qualitativa dos perfis de gestantes onde o modelo apresenta falhas de predição.

15.7. Conclusão Preliminar

Os dados sustentam a premissa de que fatores não clínicos são determinantes na decisão da via de parto no Brasil. O modelo atual serve como uma base sólida para políticas de intervenção e para o refinamento da coleta de dados assistenciais.

16. Esboço do Storytelling

16.1. O Cenário

O Brasil enfrenta um dilema conhecido como a "Epidemia de Cesáreas". Embora as diretrizes da Organização Mundial da Saúde (OMS) preconizem o parto normal como a via preferencial para gestações de baixo risco, a realidade dos dados do SINASC revela um cenário onde a intervenção cirúrgica se tornou, frequentemente, a regra e não a exceção.

16.2. Random Forest

Para investigar, utilizamos o algoritmo Random Forest como uma lente analítica. Ao processar 3,5 milhões de registros entre 2022 e 2023, o modelo não buscou apenas correlações clínicas, mas tentou encontrar padrões ocultos entre variáveis socioeconômicas, demográficas e operacionais. O modelo mapeou o comportamento sistêmico do atendimento obstétrico brasileiro, tratando cada registro como uma peça de um quebra-cabeça.

16.3. A Descoberta dos Dados

Esperava-se que fatores biológicos fossem os maiores preditores da via de parto. No entanto, o dado mais relevante foi o Número de Consultas de Pré-Natal. O modelo aponta que o aumento na frequência das consultas, que deveria ser um indicador de maior segurança e preparo para o parto natural, correlaciona-se inversamente com a via vaginal. O contato frequente com o sistema de saúde parece funcionar, estatisticamente, como um condutor à cesárea agendada. O pré-natal, nesta ótica, está atuando como um indutor de conveniência logística, e não como suporte ao bem-estar da paciente.

16.4. Quantificando a Subjetividade

A acurácia de 63% poderia ser vista como uma limitação, porém, neste estudo, o "erro" é um achado muito importante. Se o modelo atingisse 100% de precisão, significaria que a via de parto é um evento puramente matemático e determinístico. O fato de o modelo "errar" 37% das vezes confirma a hipótese: a via de parto no Brasil é profundamente influenciada por variáveis que não estão no SINASC. Esse gap de 37% quantifica a subjetividade, a conveniência de agendamento por parte dos profissionais e o sistema privado de saúde. A acurácia de 63% não é uma falha de software, mas o retrato estatístico de que o parto no Brasil é um evento social.

16.5. Considerações Finais

Os dados validam que a "Epidemia de Cesáreas" não é apenas um problema de "médicos que operam demais", mas de um sistema que incentiva o agendamento em detrimento da espera ativa. Ao final desta análise, o modelo Random Forest deixa de ser apenas uma ferramenta de classificação e passa a ser uma ferramenta de denúncia epidemiológica. Ele sugere que, para reduzir as taxas de cesárea, as

políticas públicas precisam olhar menos para o prontuário clínico isolado e mais para o fluxo operacional do pré-natal. Os números confirmam que a mudança na via de parto brasileira requer menos tecnologia e mais mudança de cultura assistencial.

17. Link da Apresentação no Youtube

<https://youtu.be/iNgtlqxJJiM>

18. Referências

MINISTÉRIO DA SAÚDE. Sistema único de Saúde (SUS). Governo do Brasil, 2026. Disponível em <https://www.gov.br/saude/pt-br/sus>. Acesso em 10 mar 2026.

MINISTÉRIO DA SAÚDE. Departamento de Análise Epidemiológica e Vigilância de Doenças Não Transmissíveis. Governo do Brasil, 2026. Disponível em <https://svs.aids.gov.br/daent/centrais-de-conteudos/paineis-de-monitoramento/natalidade/regularidade>. Acesso em 12 mar 2026.

MINISTÉRIO DA SAÚDE. SUS. Sistema de Informações sobre Nascidos Vivos. Governo do Brasil, 2026. Disponível em <https://www.gov.br/saude/pt-br/composicao/svsa/sistemas-de-informacao/sinasc>. Acesso em 12 mar 2026.

MINISTÉRIO DA SAÚDE. DataSUS. Governo do Brasil, 2026. Disponível em: <http://siab.datasus.gov.br/DATASUS/index.php?area=060305>. Acesso em 10 mar 2026.